运动先验与强化学习算法

DeepMimic · AMP · GMP

原理、核心公式、训练流程与工程实现

技术学习笔记

研究方向：人形机器人运动控制、物理仿真、模仿学习与强化学习

阅读提示：本文将论文核心思想与教学性简化表达分开说明。公式中的符号应结合各论文具体状态定义、坐标系和实现细节理解。

摘要

本文梳理三种与机器人自然运动学习密切相关的方法：DeepMimic、Adversarial Motion Priors（AMP）和 Generative Motion Prior（GMP）。三者都利用参考运动数据改善强化学习策略，但构造运动监督信号的方式不同。

DeepMimic通过参考轨迹与实际运动之间的显式误差构造模仿奖励；AMP训练判别器区分参考运动与策略生成运动， 再把判别器输出转换成风格奖励；GMP训练生成模型，根据当前运动状态和指令生成未来参考运动，再用运动跟踪奖 励指导强化学习。

理解三者时，应重点区分：参考轨迹跟踪、运动分布判别、条件运动生成。这三种监督机制决定了网络结构、训练 流程、数据组织方式和适用任务。

目录

一、研究背景与共同基础

二、DeepMimic：显式参考运动跟踪

三、AMP：对抗式运动先验

四、GMP：生成式运动先验

五、三种算法的系统比较

六、工程实现与调试建议

七、学习路线与术语表

八、参考文献

一、研究背景与共同基础

1.1 为什么需要运动先验

仅依靠任务奖励训练机器人，可能得到能够完成目标、但运动形态不自然的策略。例如机器人能够达到指定前进速 度，却出现膝关节过度弯曲、身体晃动、手臂摆动不协调或能耗过高等现象。

运动先验（Motion Prior）是从已有运动数据中学习到的运动规律，可用于约束或引导策略生成自然动作。常见数 据来源包括人体动作捕捉（MoCap）、机器人遥操作数据以及仿真生成的运动轨迹。

$$\pi^* = \arg\max_{\pi} \mathbb{E}_{\pi}\left[\sum_{t=0}^{T} \gamma^t r_t\right] \tag{1-1}$$

其中，π 为策略，r_t 为奖励，γ 为折扣因子。运动先验通常不是取代强化学习，而是改变奖 励、观测或参考目标，使策略更容易学到符合运动规律的行为。

1.2 三种方法的核心差别

方法	监督信号	核心问题
DeepMimic	机器人状态与指定参考帧之间的误差	如何跟踪某个参考动作?
AMP	判别器对运动状态转移的评分	生成运动是否符合参考运动分布?
GMP	生成模型预测的未来运动参考	在当前状态和指令下，下一步自然运动是什么?

三者都可以与 PPO 等策略优化算法结合，但它们的运动先验模块承担不同职责。

二、DeepMimic：显式参考运动跟踪

2.1 基本思想

DeepMimic（DeepMimic: Example-Guided Deep Reinforcement Learning of Physics-Based Character Skills）由 Peng 等人提出，发表于 SIGGRAPH 2018。其目标是让物理角色通过强化学习复现参考运动，同时能够 根据真实物理状态调整动作，而不是机械播放动画。

训练时，系统从参考运动片段中取得当前目标姿态和速度，策略根据机器人状态及参考运动进度输出控制动作。物 理引擎执行动作后，系统比较实际运动与参考运动并计算模仿奖励。

2.2 状态、参考运动与策略

$$s_t = (q_t, \dot{q}_t, p_t, \dot{p}_t) \tag{2-1}$$

这里的符号是概念性表示：q_t 表示关节/身体姿态，q _t 表示速度，p_t 与 p _t 表示根节点或身体位置、速度。具体状态向量依机器人模型而定。

$$a_t = \pi_\theta(s_t, \phi_t, g_t) \tag{2-2}$$

其中 ϕ_t 表示参考动作相位或时间进度，g_t 表示可选任务目标。参考运动可表示为一段按时间索引的状态序列。

2.3 模仿奖励

DeepMimic 将模仿奖励分解为多个运动学误差项。常见表达如下：

$$r_t^I = w_p r_t^p + w_v r_t^v + w_e r_t^e + w_c r_t^c \tag{2-3}$$

姿态奖励比较实际关节旋转与参考关节旋转。原论文使用旋转差异度量，而非简单把所有四元数分量直接相减：

$$r_t^p = \exp\left(-2\sum_j \|\hat{q}_t^j \ominus q_t^j\|^2\right) \tag{2-4}$$

速度奖励比较实际关节速度与参考关节速度：

$$r_t^v = \exp\left(-0.1\sum_j \|\hat{\dot{q}}_t^j - \dot{q}_t^j\|^2\right) \tag{2-5}$$

末端执行器奖励约束手、脚等关键末端的位置：

$$r_t^e = \exp\left(-40\sum_e \|\hat{p}_t^e - p_t^e\|^2\right) \tag{2-6}$$

质心奖励约束整体质心位置：

$$r_t^c = \exp\left(-10\|\hat{p}_t^c - p_t^c\|^2\right) \tag{2-7}$$

上述系数对应论文中的典型奖励定义；不同复现代码可能因单位、状态归一化和实现版本而调整。 $\ominus$ 表示旋转空间中的差异运算。

2.4 Phase、RSI 与 Early Termination

Phase：描述当前参考动作进度。对于周期动作可以循环推进；对于有限时长技能则随动作时间推进。

Reference State Initialization（RSI）：从参考动作不同时间点初始化训练状态，避免策略只学会从动作第一帧开始执行。

Early Termination：当角色严重偏离有效状态或发生失败时提前终止，减少无效采样。

2.5 PPO 优化

$$L^{CLIP}(\theta) = \mathbb{E}_t\left[\min\left(\rho_t A_t, \text{clip}(\rho_t, 1-\epsilon, 1+\epsilon)A_t\right)\right] \tag{2-8}$$

$$\rho_t = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)} \tag{2-9}$$

PPO 利用优势函数 A_t 更新策略。DeepMimic 的关键在于构造参考跟踪奖励；PPO 是策略优化器，并非 DeepMimic 独有。

2.6 优缺点与适用场景

优势：监督信号直观、可精确跟踪指定技能、适合后空翻等有明确参考时序的高动态动作。

局限：需要参考动作时间对齐；奖励权重和坐标定义影响明显；多个动作技能的切换与组合需要额外设计。

适用：指定动作复现、运动技能学习、轨迹跟踪和动作质量评估。

三、AMP：对抗式运动先验

3.1 基本思想

AMP（Adversarial Motion Priors for Stylized Physics-Based Character Control）由 Peng 等人提出，发表于 SIGGRAPH 2021。它不要求策略逐帧跟踪某一条指定轨迹，而是训练一个判别器，区分参考运动数据与当前策略生成 的运动。策略则通过最大化风格奖励，学习生成与参考数据分布相似的运动。

3.2 运动特征与判别器

$$x_t = (\Phi(s_t), \Phi(s_{t+1})) \tag{3-1}$$

判别器输入相邻状态的运动特征。Phi 是特征映射，可包括根节点速度、局部关节旋转、关节速度及关键身体 部位位置等。相邻状态使判别器不仅看到姿态，也能观察运动变化。

$$D_\psi(x_t) \in \mathbb{R} \tag{3-2}$$

AMP 的判别器输出是实数分数，不是经过 Sigmoid 限制的概率。

3.3 Least-Squares 判别器损失

$$\begin{aligned} L_D = {} & \mathbb{E}_{x\sim\mathcal{M}}[(D_\psi(x)-1)^2] \\ & + \mathbb{E}_{x\sim\pi}[(D_\psi(x)+1)^2] \end{aligned} \tag{3-3}$$

其中 M 表示参考运动分布，π 表示当前策略产生的运动分布。真实样本的目标标签为 +1，生成样本的目标标签为 -1。

3.4 Gradient Penalty

$$L_{GP} = \mathbb{E}_{x\sim\mathcal{M}}\left[\|\nabla_x D_\psi(x)\|^2\right] \tag{3-4}$$

$$L_D^{total} = L_D + \lambda_{GP} L_{GP} \tag{3-5}$$

梯度惩罚用于约束判别器对输入变化的敏感程度。AMP 的这一正则项不能与 WGAN-GP 中将梯度范数约束到 1 的形式混为一谈。论文实现还可能包含其他正则化细节。

3.5 Style Reward

$$r_t^S = \max\left(0,\ 1 - \frac{1}{4}(D_\psi(x_t) - 1)^2\right) \tag{3-6}$$

奖励在判别器输出接近 +1 时较高，输出距离 +1 越远，奖励越低。它是围绕 +1 的非负函数，而不是“判别器分数越大，奖励必然越大”。

判别器输出 D	风格奖励	解释
-1.0	0	与真实运动目标差异较大
-0.5	0.4375	较低奖励
0.0	0.75	中等偏高
0.5	0.9375	较高奖励
1.0	1.0	达到最大值
2.0	0.75	超过目标值后奖励下降

3.6 任务奖励与风格奖励

$$r_t = w^G r_t^G + w^S r_t^S \tag{3-7}$$

任务奖励决定机器人要做什么，例如跟踪目标速度；风格奖励约束机器人如何运动，例如保持自然步态。二者共同 引导策略。

3.7 Replay Buffer 与交替训练

AMP 通常为判别器维护生成运动的 Replay Buffer，存储历史策略产生的运动特征。判别器从参考数据和缓冲区中分别采样真实、生成样本。该缓冲区与 PPO 使用的 On-policy Rollout Buffer 不同。

策略与环境交互，收集状态转移和任务奖励。

根据判别器输出计算风格奖励。

将生成运动特征写入 Replay Buffer。

使用真实运动与生成运动更新判别器。

使用组合奖励通过 PPO 更新策略和值函数。

重复上述过程，形成交替优化。

3.8 优缺点与适用场景

优势：无需逐帧指定参考动作；可从多个运动片段学习风格；能将任务目标与运动风格相对解耦。

局限：判别器与策略的对抗训练可能不稳定；风格奖励是标量，不能直接指出某个关节应如何修正；特征设计和 数据覆盖很重要。

适用：自然步态、多运动片段风格学习、由任务奖励驱动的运动生成。

四、GMP：生成式运动先验

4.1 基本思想

GMP（Generative Motion Prior）相关工作《Natural Humanoid Robot Locomotion with Generative Motion Prio r》提出利用生成模型学习机器人运动数据的条件分布。模型根据当前运动状态和速度指令生成未来参考运动，再由强化学习策略学习跟踪这些参考。

与 AMP 输出风格评分不同，GMP 直接提供可用于跟踪的运动量，例如关节状态和关键点位置。

4.2 数据准备与运动重定向

GMP 需要先将人体 MoCap 数据转换为机器人形态下的运动数据（Motion Retargeting）。人体与机器人在身高、肢 体比例、关节自由度和关节限位方面可能不同，因此不能简单复制人体关节角度。

重定向后的运动还应检查关节限位、足底接触、身体穿透、坐标系和时间采样一致性。生成模型学到的上限很大程 度取决于训练数据质量。

4.3 运动状态表示

$$m_t = (v_t^{base}, \omega_t^{base}, q_t, p_t^{key}, v_t^{key}) \tag{4-1}$$

其中包含根节点线速度、根节点角速度、关节状态、关键点位置和关键点速度。具体维度及坐标系以论文实现为准 。

4.4 CVAE：条件变分自编码器

CVAE 学习给定当前运动状态时，下一帧运动的条件分布。Encoder 根据当前帧与真实下一帧估计潜变量分布；Decoder 根据当前状态和潜变量重建下一帧。

$$q_\theta(z|m_t, m_{t+1}) = \mathcal{N}(\mu_\theta, \mathrm{diag}(\sigma_\theta^2)) \tag{4-2}$$

$$z = \mu_\theta + \sigma_\theta \odot \epsilon, \qquad \epsilon \sim \mathcal{N}(0, I) \tag{4-3}$$

$$\hat{m}_{t+1} = f_\phi(z, m_t) \tag{4-4}$$

重建损失：

$$L_{rec} = \|\hat{m}_{t+1} - m_{t+1}\|_2^2 \tag{4-5}$$

KL 散度损失：

$$L_{KL} = D_{KL}\left(q_\theta(z|m_t, m_{t+1}) \,\|\, \mathcal{N}(0, I)\right) \tag{4-6}$$

CVAE 总损失：

$$L_{CVAE} = L_{rec} + \beta L_{KL} \tag{4-7}$$

重参数化技巧使采样过程能够通过均值和方差进行梯度传播。KL 项将潜变量分布约束到先验分布附近，重建项则要求生成结果保留运动信息。

4.5 自回归运动生成

$$\hat{m}_{t+1} = f_\phi(z_{t+1}, m_t) \tag{4-8}$$

$$\hat{m}_{t+2} = f_\phi(z_{t+2}, \hat{m}_{t+1}) \tag{4-9}$$

模型可以将前一步预测作为下一步输入，逐步生成未来运动序列。自回归生成的优点是可延长预测时域；风险是预 测误差可能逐步累积，因此需要关注训练与推理输入分布差异。

4.6 Command Encoder

$$z_{t+1} = f_\psi(c_t, m_t) \tag{4-10}$$

$$\hat{m}_{t+1} = f_\phi(z_{t+1}, m_t) \tag{4-11}$$

Command Encoder 根据目标速度指令 c_t 和当前运动状态 m_t 产生潜变量，再交给冻结的 Motion Decoder 生成参考运动。它学习的是通过潜变量控制生

成结果，使其符合目标速度条件。

4.7 Motion Guidance Reward

生成模型输出参考关节状态和关键点位置，策略执行后将实际运动与参考运动比较。论文给出的引导奖励形式包括 ：

$$r_{dof} = \exp\left(-0.7\|q - q_{ref}\|\right) \tag{4-12}$$

$$r_{keypos} = \exp\left(-0.7\|p - p_{ref}\|\right) \tag{4-13}$$

$$r_{guidance} = r_{dof} + r_{keypos} \tag{4-14}$$

这里保留论文所示范数形式，不应未经核对改成平方范数。实现时还需确认关节角度、位置的归一化和坐标定义。

4.8 任务奖励与 PPO

$$r_t = r_{guidance} + r_{task} + r_{reg} \tag{4-15}$$

任务奖励通常包含线速度和角速度跟踪。论文给出的典型形式为：

$$r_{lin} = \exp\left(-4\|v_{xy} - c_{xy}\|^2\right) \tag{4-16}$$

$$r_{ang} = \exp\left(-4\|\omega - c_{\omega}\|^2\right) \tag{4-17}$$

$$r_{task} = w_{lin} r_{lin} + w_{ang} r_{ang} \tag{4-18}$$

其中论文对应的权重为 w_1in=3.0、w_ang=2.5。总奖励还包含正则化项，具体实现需查看论文和代码配置。

GMP 生成模型在离线阶段训练，进入 PPO 阶段后通常冻结；在线更新的重点是控制策略和价值网络。

4.9 优缺点与适用场景

优势：提供显式、细粒度的未来运动参考；可以通过条件编码器响应速度指令；生成模型与 PPO 分阶段训练，避免在线对抗优化。

局限：依赖高质量重定向数据；生成运动不一定天然满足机器人动力学；自回归预测可能累积误差；条件分布覆 盖范围影响泛化。

适用：以自然步态为目标的人形机器人行走、速度条件运动生成、运动参考引导控制。

五、三种算法的系统比较

维度	DeepMimic	AMP	GMP
先验形式	显式参考轨迹	隐式运动分布	条件生成运动
核心模块	Policy + Value	Policy + Value + Discriminator	CVAE/生成器 + Command Encoder + Policy

监督信号	姿态、速度、末端、质心误差	判别器风格分数	关节与关键点跟踪误差
时间信息	典型实现显式跟踪参考进度	不要求显式逐帧 Phase	自回归预测未来运动
是否需要判别器	否	是	否
是否需要生成模 型			
否	否	是	

主要风险	时间对齐与奖励设计	对抗训练稳定性	生成误差与分布外输入
典型目标	指定技能模仿	风格学习与多片段运动	条件自然运动生成

5.1 用一个任务理解差异

假设训练人形机器人以 1.0 m/s 向前行走:

DeepMimic: 从参考步态的对应相位取得目标姿态和速度, 机器人跟踪该参考轨迹。

AMP: 判别器比较机器人生成的运动转移与参考步态分布, 策略最大化风格奖励, 同时跟踪速度任务。

GMP: 根据当前运动状态和 1.0 m/s 指令生成未来参考运动, 策略跟踪生成的关节和关键点目标。

5.2 不要误解的三点

DeepMimic 并非只能学习单一动作; 多片段训练和技能组合也可以实现, 只是核心监督仍是显式参考跟踪。

AMP 并非完全不使用时间信息; 它使用相邻状态特征, 但通常不要求策略按某个参考片段的显式 Phase 逐帧跟踪。

GMP 不是 PPO 的替代品；它提供生成式运动参考，强化学习策略仍负责在物理环境中学习控制。

六、工程实现与调试建议

6.1 通用模块

模块	职责	关键检查
Motion Dataset	加载和采样参考运动	采样频率、缺帧、单位、坐标系
Retargeting	人体运动映射到机器人	关节限位、接触、比例和可达性
Observation Builder	构造策略/先验输入	维度顺序、归一化、历史帧
Policy / Value	控制动作与价值估计	输入维度、动作缩放、稳定性
Reward	计算任务和运动先验奖励	量纲、权重、数值范围
Physics Engine	执行控制并更新状态	仿真步长、接触、PD 参数

6.2 三种方法的实现关注点

DeepMimic：首先验证参考轨迹插值、Phase 推进、四元数误差和 RSI。建议先用单个简单动作片段确认奖励随跟踪误差变化正确，再逐步增加技能复杂度。

AMP：首先确认真实与生成样本采用完全一致的特征定义、坐标系和归一化。检查判别器输出分布、Real/Fake Loss、Gradient Penalty 和 Style Reward 是否出现饱和。

GMP：先单独评估 CVAE 的下一帧重建和多步自回归误差，再训练 Command Encoder。进入 PPO 前，检查生成参考运动是否符合速度指令、关节限位和机器人可达性。

6.3 常见错误

把判别器输出当成概率并在 AMP 判别器末尾使用 Sigmoid。

将 AMP 判别器 Replay Buffer 与 PPO On-policy Rollout Buffer 混为一谈。

不同模块使用不同坐标系，导致奖励数值没有物理意义。

直接将人体关节角度复制给机器人，忽略运动重定向。

只看总奖励，不分别记录 Task Reward、Style/Guidance Reward 和正则项。

只验证单步生成质量，不检查 GMP 多步自回归误差。

6.4 推荐日志

算法	建议记录的指标
DeepMimic	Pose/Velocity/End-Effector/COM Reward、Episode Length、跟踪误差、失败率
AMP	Real Loss、Fake Loss、GP、判别器输出分布、Style Reward、Task Reward
GMP	CVAE Reconstruction Loss、KL Loss、多步预测误差、Command 速度误差、DOF/Keypoint Reward、Task Reward

七、学习路线与术语表

7.1 推荐学习顺序

基础：MDP、Policy Gradient、Actor-Critic、PPO、GAE、机器人运动学与动力学。

DeepMimic：MoCap、Motion Retargeting、Phase、Pose Reward、Velocity Reward、RSI。

AMP：GAN、LSGAN、判别器、Gradient Penalty、Style Reward、Replay Buffer。

GMP：VAE、CVAE、重参数化、KL Divergence、自回归生成、Command Encoder。

工程：PyTorch、Isaac Gym/Isaac Lab、物理仿真、PD 控制、Sim-to-Real。

7.2 术语表

术语	含义
MoCap	Motion Capture，动作捕捉数据
Motion Retargeting	将一种骨架/形态的运动映射到另一种骨架/机器人
Motion Prior	从运动数据中学习到的运动规律或先验
Phase	参考动作的时间进度或周期相位

术语	含义
Discriminator	判别器，区分参考运动与策略生成运动
Style Reward	由判别器分数构造的风格奖励
CVAE	Conditional Variational Autoencoder，条件变分自编码器
Latent Variable	潜变量，生成模型中表示变化模式的隐空间变量
Autoregressive	自回归，使用前一步输出生成后续输出
PPO	Proximal Policy Optimization，近端策略优化
RSI	Reference State Initialization，参考状态初始化

八、总结

DeepMimic、AMP 和 GMP 的共同目标，是利用已有运动数据改善物理角色或机器人的运动质量。它们的区别在于如 何把运动数据转化为策略可利用的监督信号。

$$\text{DeepMimic: Reference Motion} \rightarrow \text{Tracking Error} \rightarrow \text{Reward} \tag{8-1}$$

$$\text{AMP: Motion Data} \rightarrow \text{Discriminator} \rightarrow \text{Style Reward} \tag{8-2}$$

$$\text{GMP: Motion Data} \rightarrow \text{Generator} \rightarrow \text{Future Reference} \rightarrow \text{Tracking Reward} \tag{8-3}$$

简要记忆：DeepMimic 关注“跟踪指定动作”；AMP 关注“动作是否符合运动风格”；GMP 关注“根据状态和指令 生成未来自然运动”。这是一种概念上的技术分类，不代表严格的算法继承关系，也不意味着后者在所有任务中都 优于前者。

研究时应回到原论文核对具体状态定义、奖励权重、归一化方式和训练时序；同名算法的开源复现可能存在实现差 异。

参考文献

[1] Peng, X. B., Abbeel, P., Levine, S., & van de Panne, M. (2018). DeepMimic: Example-Guided Deep Reinforcement Learning of Physics-Based Character Skills. ACM Transactions on Graphics, 37(4).

论文：https://arxiv.org/abs/1804.02717

项目：https://xbpeng.github.io/projects/DeepMimic/

[2] Peng, X. B., Ma, Z., Abbeel, P., Levine, S., & Kanazawa, A. (2021). AMP: Adversarial Motion Priors for Stylized Physics-Based Character Control. ACM Transactions on Graphics, 40(4).

论文与项目：https://xbpeng.github.io/projects/AMP/

[3] Zhang, H. et al. (2025). Natural Humanoid Robot Locomotion with Generative Motion Prior. arXiv preprint.

论文：https://arxiv.org/abs/2503.09015

项目：https://sites.google.com/view/humanoid-gmp/

[4] Schulman, J. et al. (2017). Proximal Policy Optimization Algorithms. arXiv:1707.06347.

论文：https://arxiv.org/abs/1707.06347

注：本笔记用于学习与技术梳理。具体公式、系数和代码实现应以对应论文正文、补充材料及官方实现为准。